FORTEBANK DATATHON · ИССЛЕДОВАТЕЛЬСКИЙ ПРОТОТИП

Локальный видеоаудит с проверяемыми событиями

Найти важный момент, показать кадр и объяснить наблюдаемое действие — сохраняя обработку видео внутри сервиса команды.

Qwen3-VL · локальная GPU · проверка человеком

ЗАДАЧА

Одного кадра недостаточно, чтобы понять действие

Последовательность

Кто начал действие и чем оно закончилось?

Связи

Какой предмет переместился и у кого он оказался?

Состояние

Что изменилось и сохраняется после действия?

Цель — помогать разбирать запись по событиям. Наблюдение, подозрение и подтверждённое нарушение должны различаться.

РАБОЧИЙ СЦЕНАРИЙ

Видео → результат → проверка

Загрузка .mov → Очередь / статус → Вердикт + время → Кадр и описание

API

POST /api/v1/analyze
GET /api/v1/jobs/{job_id}
Авторизация X-API-Key

Локальное ревью

Полное видео, пауза, временной фрагмент, ответ модели и исправление.

Доказательство

Исходный кадр с временной меткой. Сбой обработки получает failed, а не выдуманный вердикт.

> API и редактор проверены локально. Публичный адрес требует отдельного запуска и проверки. Качество подключённого API-детектора пока недостаточно.

Демо: показать реальный локальный интерфейс; не выдавать сохранённый результат за live inference

КАК УСТРОЕН ПРОТОТИП

Локальная модель и два контура

Контур сервиса

FastAPI → очередь → локальный Qwen3-VL-4B NF4 → JSON и кадр-доказательство.

Текущий baseline не прошёл проверку качества. Новые эксперименты не подменяют его незаметно.

Исследовательский контур

Глобальная сцена → перекрывающиеся окна → действия и состояния → объединённая временная шкала.

16 кадров на окно; отдельный локальный evaluator и агрегированные метрики.

После загрузки весов inference работает без внешних AI API. Реальные кадры и семантические результаты остаются локально.

ИНЖЕНЕРНЫЙ РЕЗУЛЬТАТ

Измерили узкое место, затем исправили его

327,884 с

До: prefill глобального прохода

2,699 с

После: тот же этап и те же 16 кадров

16 / 16

Кадры сохранены в сравнении

Замена пути attention устранила измеренную проблему Windows SDPA без сокращения визуального входа.

Это измерение одного этапа исследовательского runner. Оно не означает такой же выигрыш для полного API-запроса и не доказывает рост точности.

Источник: astra6_control/CURRENT_STATE.md · performance checkpoint

ПРОВЕРКА КАЧЕСТВА

Исправления человека полезны, но ещё не дают стабильности

Один отдельный фрагмент: 4 события	Без примеров	С примерами
Полностью совпавшие события	0 / 4	1 / 4
Некорректные ссылки на объекты / получателей	2	8
Время после общей загрузки модели	94,135 с	90,269 с

> Результат смешанный: автоматическое включение отклонено. Примеры доступны только как пробный режим ручного ревью. Сохранение исправлений не переобучает веса.

Более ранний baseline плотного runner: полнота событий 1/17 на 4 видео. Это внутренняя метрика событий, а не точность вердиктов жюри.

Источник: exp_memory_001; исходные видео и описания не включены в слайды

ГОТОВНОСТЬ И СЛЕДУЮЩИЙ ШАГ

Рабочая инфраструктура. Качество — следующий рубеж.

Проверено

278 тестов. HTTP-запрос с моделью: 87,936 с на одном видео. Авторизация, очередь, дедлайны и восстановление worker.

Не подтверждено

Стабильное распознавание на новых сценах, нормативная привязка каждого события, успешная обработка любого видео за 300 секунд.

Далее

Согласовать ID участников и предметов, расширить независимую проверку, затем измерить пользу дополнительных исправлений.

Представляем воспроизводимый прототип и измеренные ограничения. Публичный запуск — только после проверки готовности и подтверждения команды.